

Extração de Grafos de Casos Clínicos (MultiCaRe)

Projeto 1 - Processamento de Linguagens Naturais 2026

Ana Luiza Paro Costa - 249728
Caio Lima Albuquerque - 288808
Giovana Jacome Marchetti - 177700
João Pedro Frare - 281260
Victor Yaegashi Setti - 206362

Metodologia e Pipeline

Uma abordagem híbrida, combinando regras formais com dicionários e ontologias clínicas, garantindo controle sobre os dados

Arquitetura do Pipeline Híbrido



1. Limpeza & Expressões

Processamento inicial do CSV e aplicação de Regex para a extração direta e otimizada de valores laboratoriais e dimensões



2. NLP Clínico

Processamento do texto através da biblioteca **SpaCy** acoplada ao **Matcher** de regras sintáticas



3. Grafo de Relações


Mapeamento de relações sintáticas entre nós (verbos de ação) e inferência de métricas por proximidade física no texto livre

Fase 1: Captura de Medidas Clínicas

A extração de resultados de exames e dosagens é feita através do mapeamento formal por Regex, permitindo a separação limpa do componente numérico e da unidade de medida

```
r'(\d+(?:,\d+)?(?:\.\d+)?)\s*(cm|mm|ng/ml|iu/ml|mg)'
```

- > Captura determinística.
- > Gera nós classificados como **ExamResult**
- > Padronização das labels unindo valor numérico e unidade (ex: "12,476.5 ng/ml").



Fase 2: Reconhecimento de Entidades

Biblioteca SpaCy e Matcher baseado em Regras

Resgata conceitos do texto e realiza o pareamento com as diferentes classes

- Identifica padrões POS (Parts of Speech), como *Adjetivo + Substantivo*
- Lematização de termos para padronização e consistência
- Remove stopwords utilizando o corpus da biblioteca NLTK
- Classifica **Patient** utilizando uma lista de termos comuns ("woman", "man", "girl", "boy", "male", "female", "patient")



Fase 2: Reconhecimento de Entidades

```
concept_matcher.add("CLINICAL_CONCEPT", [  
    [{"POS": "ADJ", "OP": "*"}, {"POS": "NOUN", "OP": "+"}],  
    [{"POS": "PROPN", "OP": "+"}])
```

- > Classifica **Procedure/Exam** usando heurísticas léxicas (ex: "endoscopy", "resection")
- > Classifica **DISEASE** (patologias e sintomas) baseado em uma lista de palavras conhecidas dessa classe ("pain", "nausea", "malignancy", "cyst", "lesion", etc)
- > Classifica **MedicalConcept** demais conceitos fora de escopo




Tabela Resultante de Nós (Vértices)

Node Type	Label Original	Label Normalizado	Span Contexto
Patient	Woman	woman	Chars 14-19
DISEASE	abdominal pain	abdominal pain	Chars 85-99
MedicalConcept	contrast	contrast	Chars 282-290
Procedure/Exam	physical examination	physical examination	Chars 229-249
ExamResult	12,476.5ng/ml	12,476.5 ng/ml	Chars 777-790

Todos os vértices são deduplicados e recebem chaves baseadas em sua versão lematizada e normalizada

Fase 3: Extração de Relacionamentos



Sintáticos Clínicos

Verbos de experiência ("present", "have") estruturam a aresta **HAS_SYMPTOM**. Ações verbais ativas ("undergo", "perform") geram **UNDERWENT_PROCEDURE**



Proximidade e Valores

Mapeamento lógico espacial: se a distância em caracteres entre um conceito médico e uma medida extraída por regex for menor que 30, cria-se a aresta **HAS_VALUE**




Suporte e Tratamento

Verbos descritivos ("reveal", "suggest") formam relações lógicas **SUPPORTS**. Intervenções verbais diretas ("treat", "resect") estruturam a aresta **TREATED_BY**


Grafo de Conhecimento Final (Arestas)

ID da Aresta	Nó Origem (Source)	Relacionamento	Nó Destino (Target)
E_003	woman	HAS_SYMPTOM	abdominal pain
E_007	contrast	SUPPORTS	computed tomography
E_016	woman	UNDERWENT_PROCEDURE	laparoscopic distal pancreatectomy
E_024	woman	TREATED_BY	postoperative day
E_042	carbohydrate antigen	HAS_VALUE	12,476.5 ng/ml



Melhorias e Limitações

- > Limitações:
 - > Método baseado em regras é preciso, mas tem baixa cobertura
 - > Se uma doença não estiver no dicionário, é classificada genericamente como 'MedicalConcept'
 - > Regras criadas para geração de arestas e nós são inflexíveis a grandes variações de vocabulário e estrutura
- > Melhorias:
 - > Listas substituídas por ontologia médica completa, como SNOMED CT ou MeSH
 - > Heurísticas baseadas em distância de termos no texto podem ser mais exploradas
 - > Uso de espaços vetoriais e métrica de similaridade de cosseno pode ser explorado para classificar melhor as similaridades entre termos.






Perguntas?

Obrigado pela atenção.

 github.com/jpfrare/MC896-NLP



Fontes de Imagens



https://www.flaticon.com/free-icon/test-results_15756053?term=medical&page=1&position=67&origin=search&related_id=15756053

Source: flaticon.com




https://www.flaticon.com/free-icon/symptoms_17084994?term=symptom&page=1&position=32&origin=search&related_id=17084994

Source: flaticon.com



https://www.flaticon.com/free-icon/cupid_2569726?term=cupid&page=1&position=6&origin=search&related_id=2569726

Source: flaticon.com



https://www.flaticon.com/free-icon/productivity_15300280?term=improvements&page=1&position=1&origin=search&related_id=15300280

Source: flaticon.com



<https://tenor.com/view/dancing-spinosaurus-gif-3344822485292694929>

Source: flaticon.com



Source: Gemini