Extração de Grafos de Casos Clínicos (Machine Learning)

Projeto 2 - Processamento de Linguagens Naturais 2026

Ana Luiza Paro Costa - 249728
Caio Lima Albuquerque - 288808
Giovana Jacome Marchetti - 177700
João Pedro Frare - 281260
Victor Yaegashi Setti - 206362

Metodologia e Pipeline

Duas abordagens distintas, uma visando melhorar diretamente o Projeto 1 com Redes Neurais e outra utilizando Regressão Logística

Arquitetura do Pipeline de Rede Neural



1. Padronização e Expansão

Extração via **Regex**, **spaCy** e **Matchers** sintáticos para gerar datasets massivos em escala, superando o custo da anotação manual.



2. Vetorização & Validação

Modelagem por **N-gramas** (sub-palavras) e avaliação estrita em **Gabarito Gold** sem vazamento de dados.



3. ML & Grafo Final

Treinamento de **Redes Neurais** para filtragem de ruído e extração de **relações** sintáticas e semânticas para o Grafo de Conhecimento.

Objetivo: Weak Supervision

Qualidade

- Dependência de pequenas bases anotadas **manualmente**.
- Processo de anotação médica extremamente **caro** e **lento**.
- Limitação drástica no volume de dados disponível para treinamento.

Quantidade & Escala

- Uso de base de dados massiva gerada automaticamente por **regras sintáticas**.
- Aceitação de rotulagem com **ruído/imperfeição** em prol da escala.
- **Hipótese Alvo:** Avaliar se Redes Neurais conseguem filtrar o ruído e extrair padrões reais a partir do alto volume de dados.

Fase 1: Padronização e Expansão

Estratégias Mantidas e Expandidas

- Manutenção das estratégias de extração originais: **spaCy**, **Regex** e **Matchers** sintáticos.
- Expansão direta para novos tipos de entidades e relações médicas do domínio.
- Garantia de consistência no processamento determinístico e extração de métricas.

Padronização para Machine Learning

Padronização estrutural do dataset para alimentação do modelo de Rede Neural:

- `e1_text` e `e1_type`: Texto e tipo da entidade de origem.
- `relation_label`: Relação sintática/semântica alvo.
- `intermediate_text`: Contexto entre as entidades para suporte ao modelo.

Tabela de Nós Antiga

Node Type	Label Original	Label Normalizado	Span Contexto
Patient	Woman	woman	Chars 14-19
DISEASE	abdominal pain	abdominal pain	Chars 85-99
MedicalConcept	contrast	contrast	Chars 282-290
Procedure/Exam	physical examination	physical examination	Chars 229-249
Value	12,476.5ng/ml	12,476.5 ng/ml	Chars 777-790

Mapeamento do Grafo: Entidades e Relações

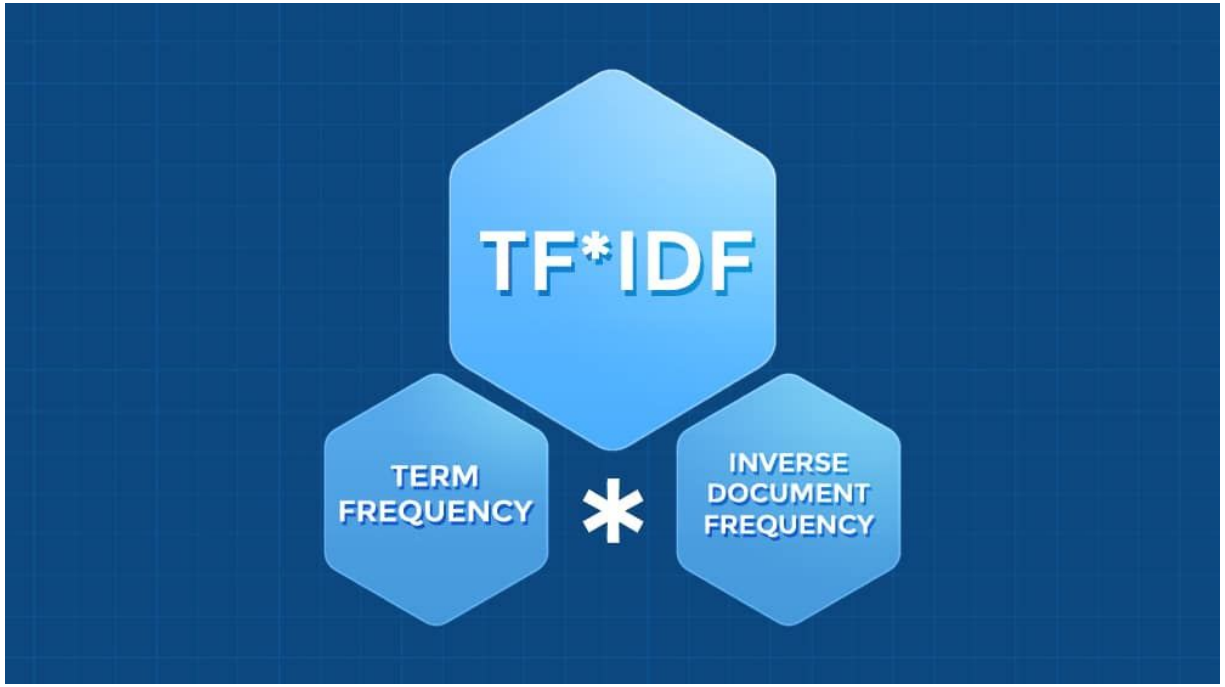
Tipos de Nós (Entidades)

- `PATIENT`: Paciente
- `VALUE`: Medida
- **`SYMPTOM`**: Sintoma do paciente.
- **`DIAGNOSIS`**: Diagnóstico identificado.
- **`FINDING`**: Achado clínico.
- **`PROCEDURE`**: Procedimentos e exames.

Tipos de Relações (Arestas)

- `HAS_SYMPTOM`: Conexão entre paciente e sintoma.
- `UNDERWENT_PROCEDURE`: Exames e procedimentos efetuados.
- `SUPPORTS`: Evidências que sustentam uma hipótese.
- `TREATED_BY`: Abordagens terapêuticas aplicadas.
- `HAS_VALUE`: Valores e medições associadas.

Fase 2: TF-IDF e N-gramas



Feature Engineering Textual

- Extraímos apenas o texto entre as duas entidades alvo (o `"intermediate_text"`).
- Para o modelo entender isso matematicamente, aplicamos a técnica de **TF-IDF** com **unigramas e bigramas**.
- Isso ensina o modelo a capturar o peso das expressões que realmente importam para definir a relação médica.

Fase 3: A Rede Preguiçosa 😴

Treinamos uma rede MLP usando PyTorch para classificação.

- **Problema:** O alto desbalanceamento dos dados fez a rede ficar “preguiçosa". O modelo estava em 87% de acurácia desde a **primeira época** apenas chutando a classe majoritária.
- **Solução:** Penalizamos de forma agressiva a Função de Perda (Loss) com **pesos inversamente proporcionais** às classes elevados a **quinta potência**. Essa estratégia forçou o nosso modelo a aprender as relações raras do domínio.



Arquitetura do Pipeline 2



1. Anotação “manual” dos Casos Clínicos

15 anotação feita pelo Google Gemini 3.1 Pro utilizando as mesmas técnicas de pré-processamento



2. Pré-processamento dos textos de teste

Lematização utilizando **SpaCy** e **Regex**, criação de janelas de **n-grama** (n≤5) e vetorização utilizando **tf-idf**



3. Treinamento de 2 modelos e predição

Modelo 1 prediz Entidade

Modelo 2 prediz Relação

Juntando os dois, podemos montar o grafo

Fase 1: Anotação Manual dos Casos

LLM simulando Anotador

Utilizando o Google Gemini 3.1 Pro para simular um profissional da saúde, foi feita a anotação de 15 casos clínicos, com o mesmo procedimento de pré-processamento do texto, mas com a ajuda da LLM, a fim de viabilizar o processo sem a contratação de um especialista.

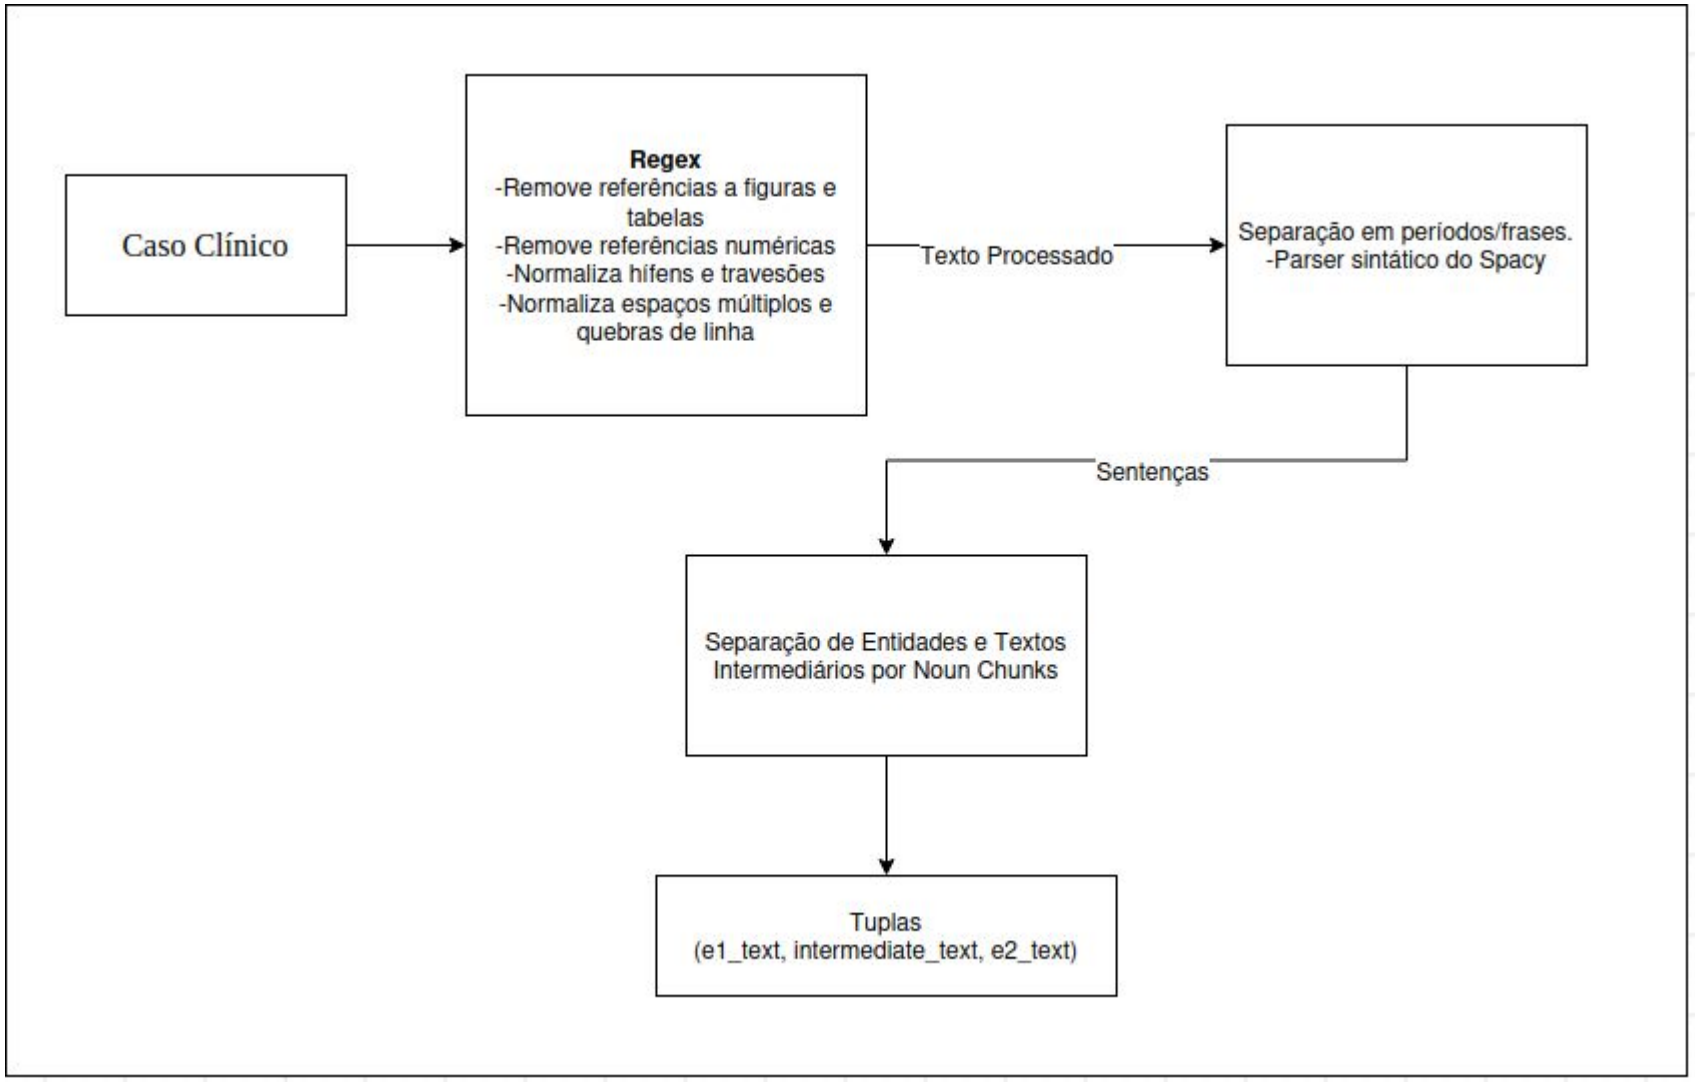
Adaptações Específicas

- Classe de entidade `NOT_ENTITY` para o primeiro modelo aprender que existem termos que não representam nada.
- Classe de relação `NO_RELATION` para o segundo modelo aprender que existem termos que, apesar de estarem entre entidades, não as relacionam de forma alguma.

Fase 1: Anotação Manual dos Casos

e1_text	e1_type	e2_text	e2_type	intermediate_text	relation_label
44-year-old woman	PATIENT	abdominal pain	SYMPTOM	presented with a 3-day history of right flank and lower quadrant	HAS_SYMPTOM
44-year-old woman	PATIENT	nausea	SYMPTOM	presented with a 3-day history of right flank and lower quadrant abdominal pain associated with	HAS_SYMPTOM
cyst	FINDING	6cm x 8cm	VALUE	measuring	HAS_VALUE
EUS_FNA	PROCEDURE	cyst	FINDING	which revealed normal pancreatic echotexture and a	SUPPORTS
pain	SYMPTOM	nausea	SYMPTOM	and	NO_RELATION

Fase 2: Processamento do Texto Completo



Fase 3: Modelos 1 e 2

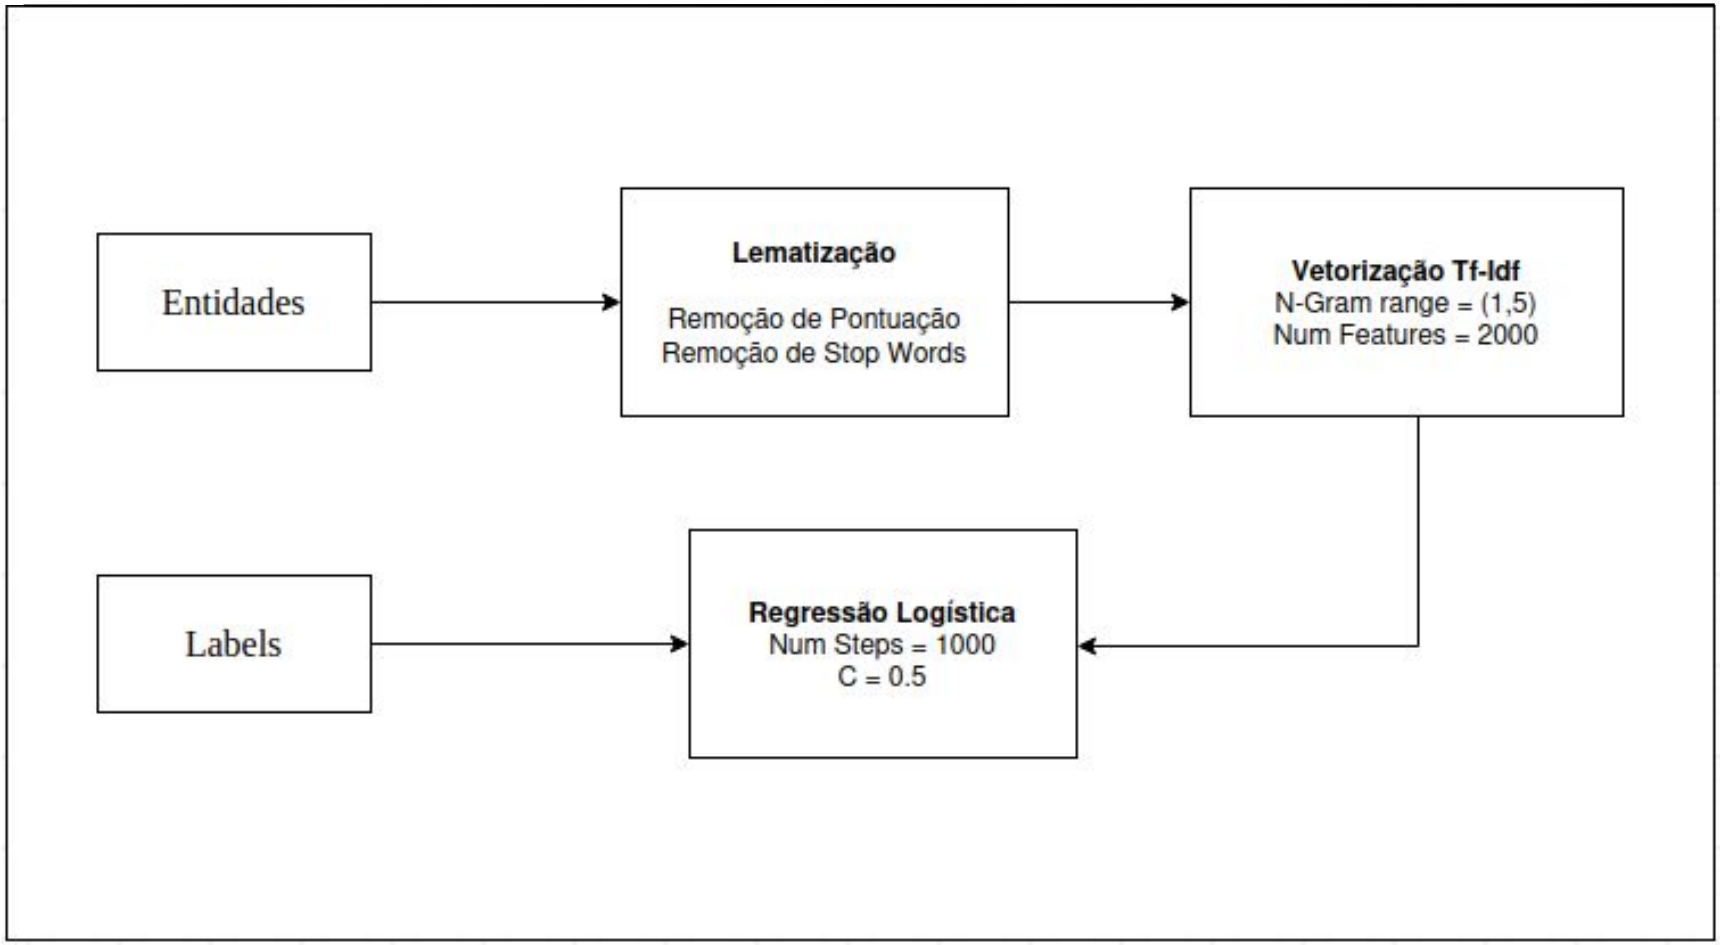
Modelo 1 (Entidades)

- Treinado com todas as anotações e1 e e2 juntas, com tuplas (texto, entidade)
- Recebe uma string de texto
- Realiza Regressão Logística
- Retorna um vetor de probabilidades
- Extremiza para a classe de maior probabilidade

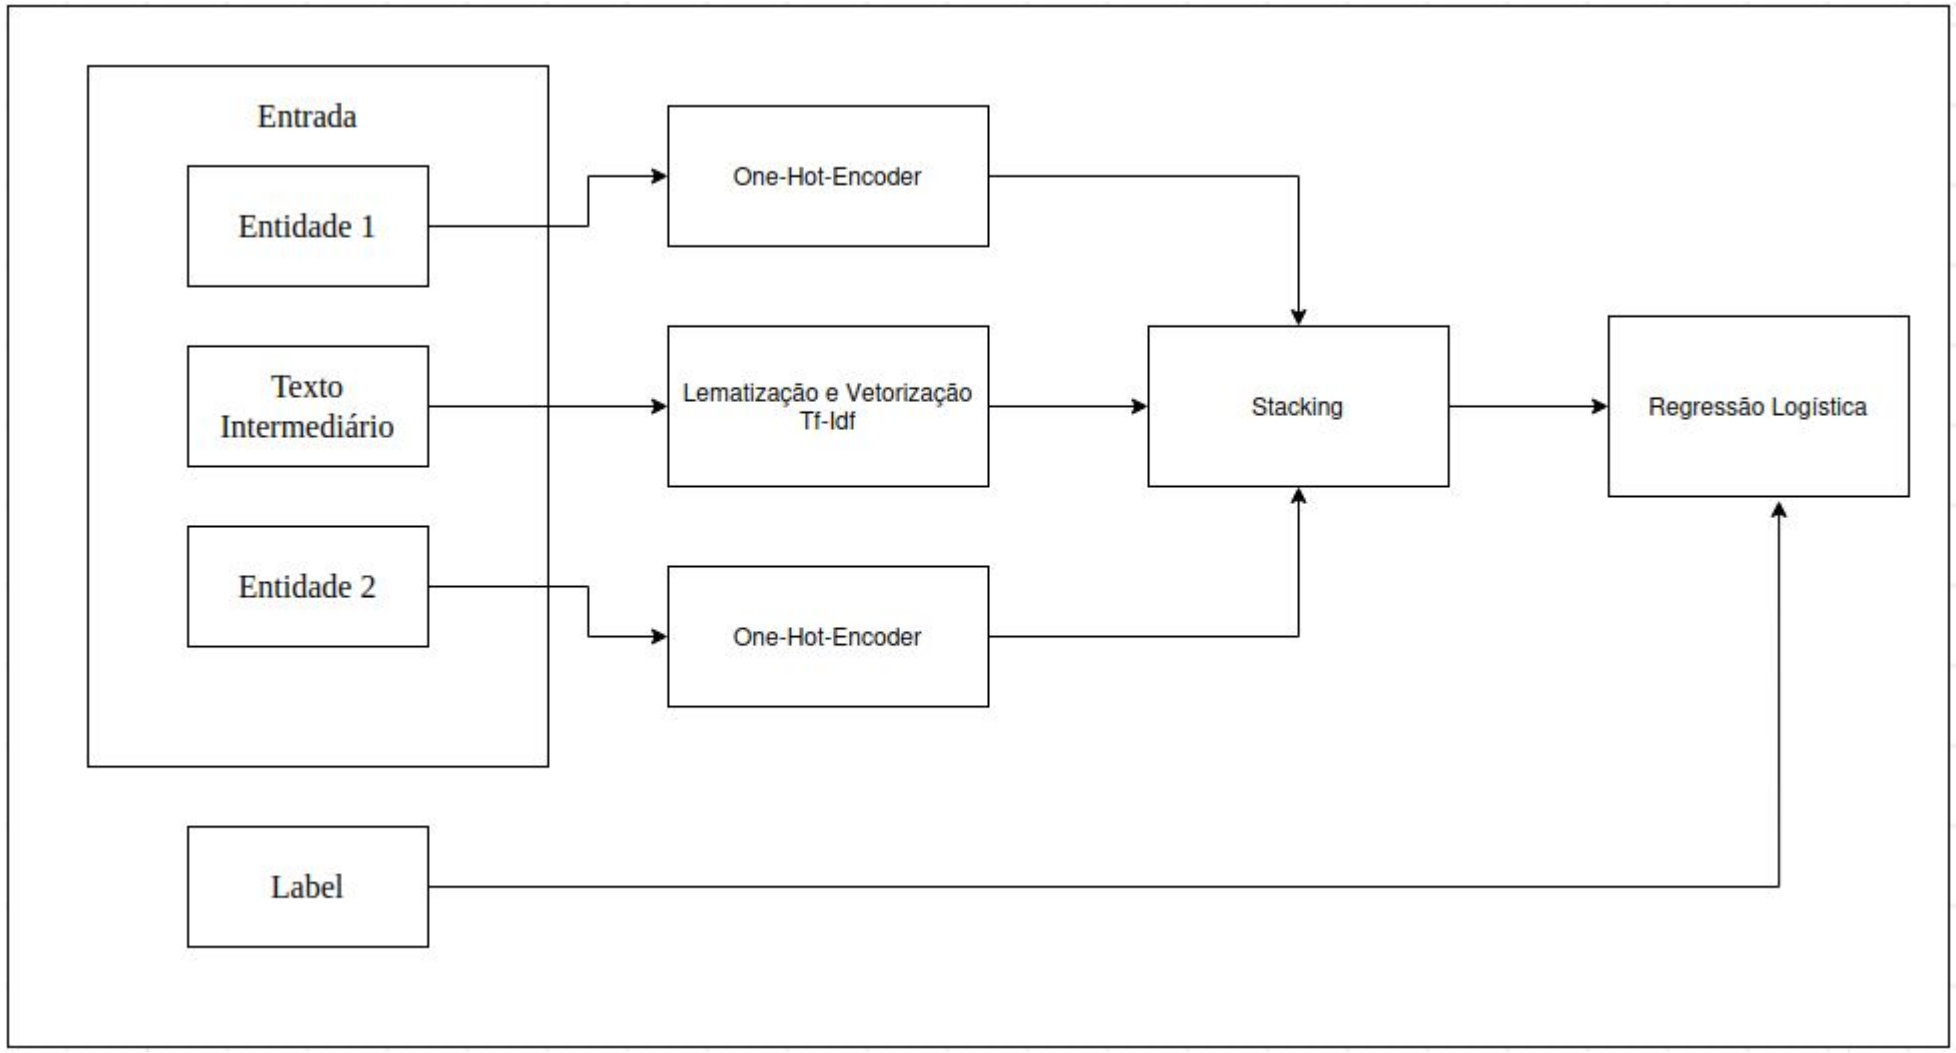
Modelo 2 (Relações)

- Treinado com triplas (entidade, entidade, texto)
- Recebe dois outputs do Modelo 1 e o intermediate_text, formando a tripla
- Realiza Regressão Logística
- Retorna um vetor de probabilidades
- Extremiza para a classe de maior probabilidade

Fase 3: Treinamento para classificação de Entidades



Fase 3: Treinamento para classificação de Relações



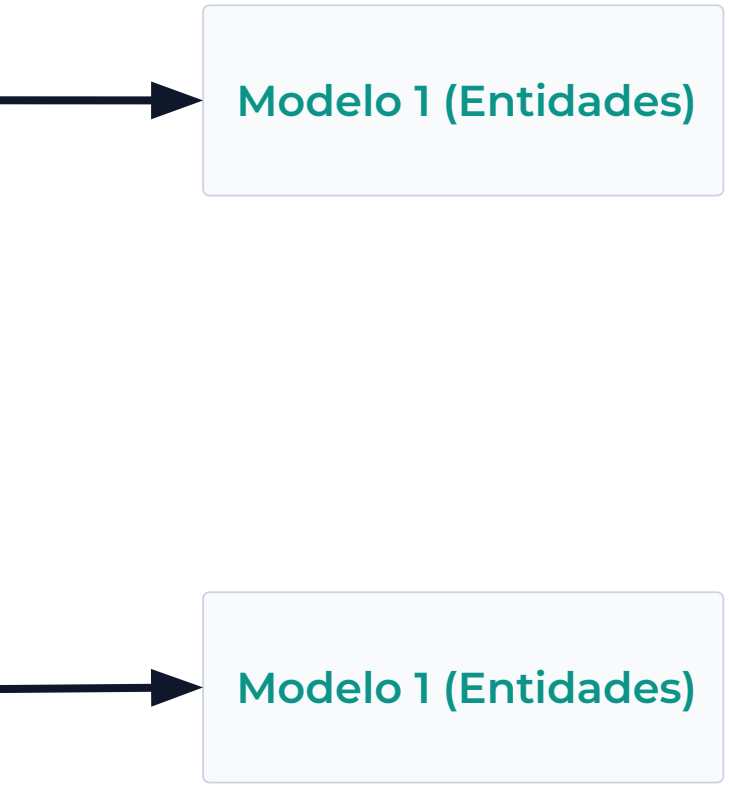
Fase 3: Integrando os Modelos 1 e 2

Fase 3: Integrando os Modelos 1 e 2

Modelo 1 (Entidades)

Modelo 1 (Entidades)

Fase 3: Integrando os Modelos 1 e 2



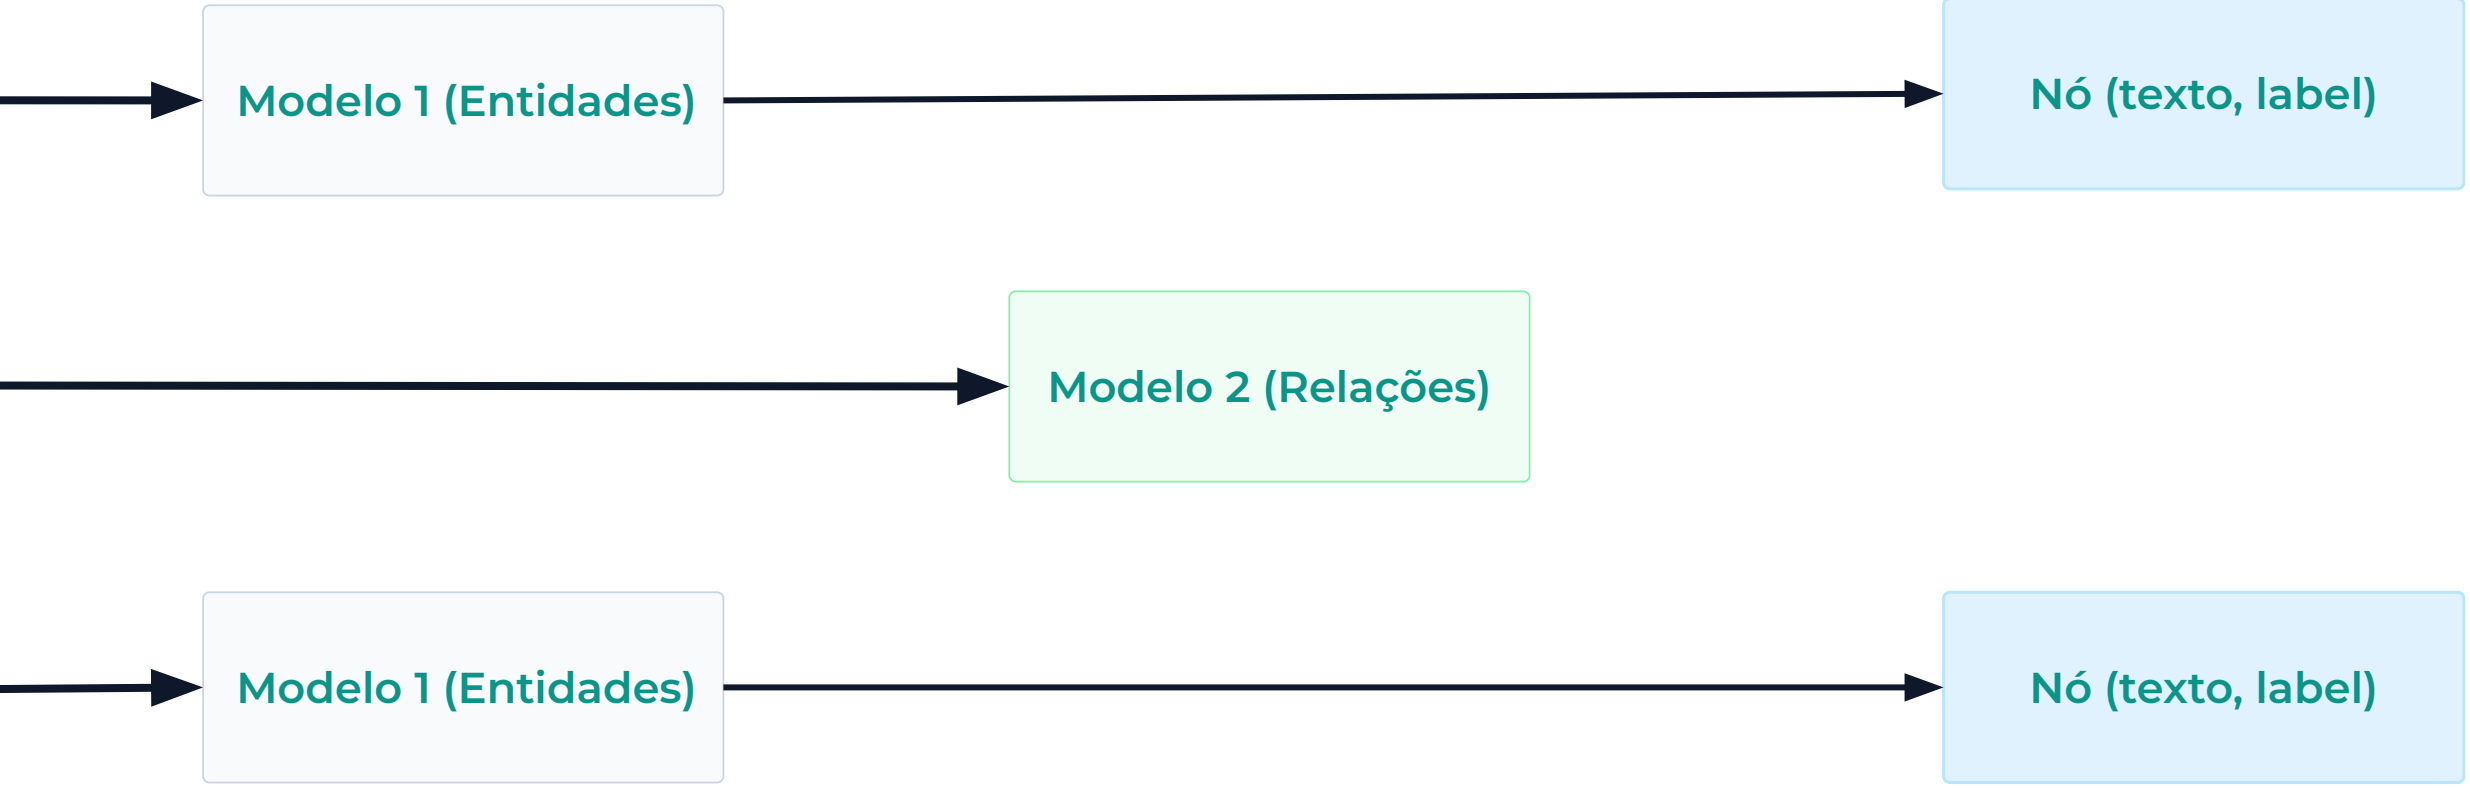
Fase 3: Integrando os Modelos 1 e 2



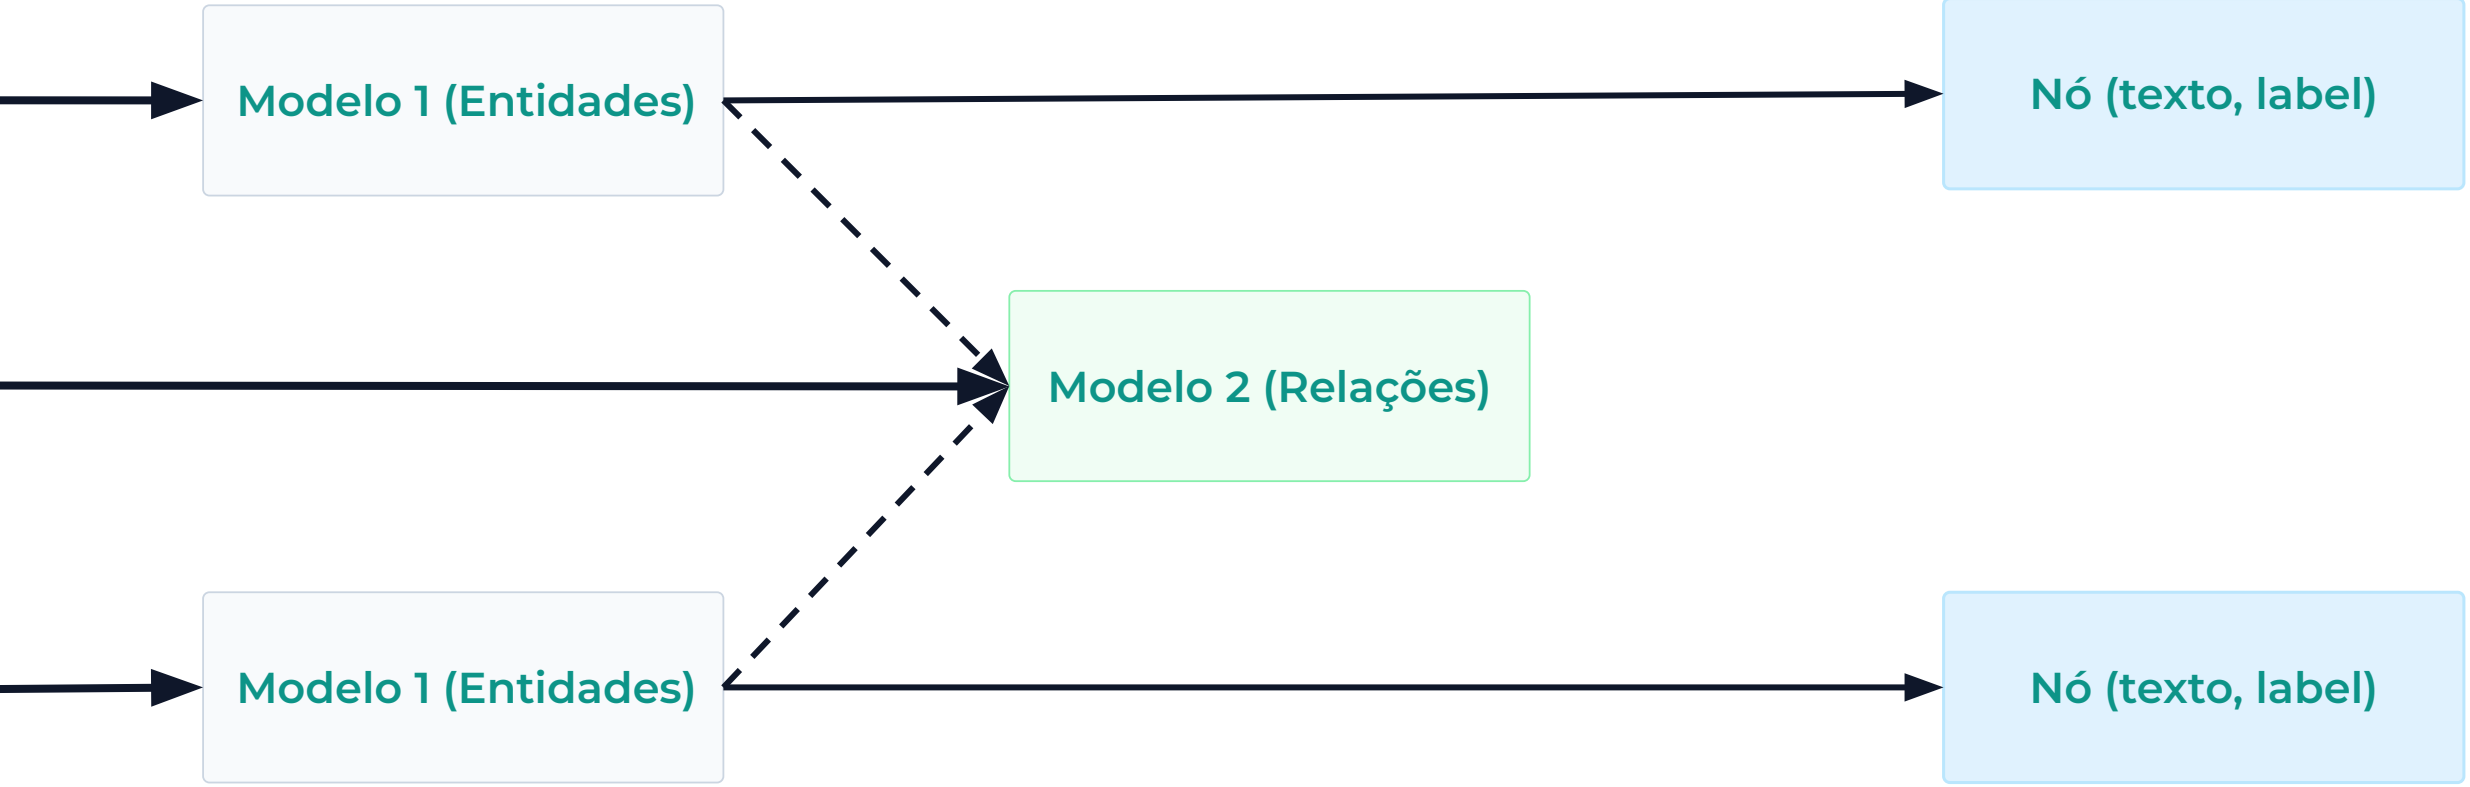
Fase 3: Integrando os Modelos 1 e 2



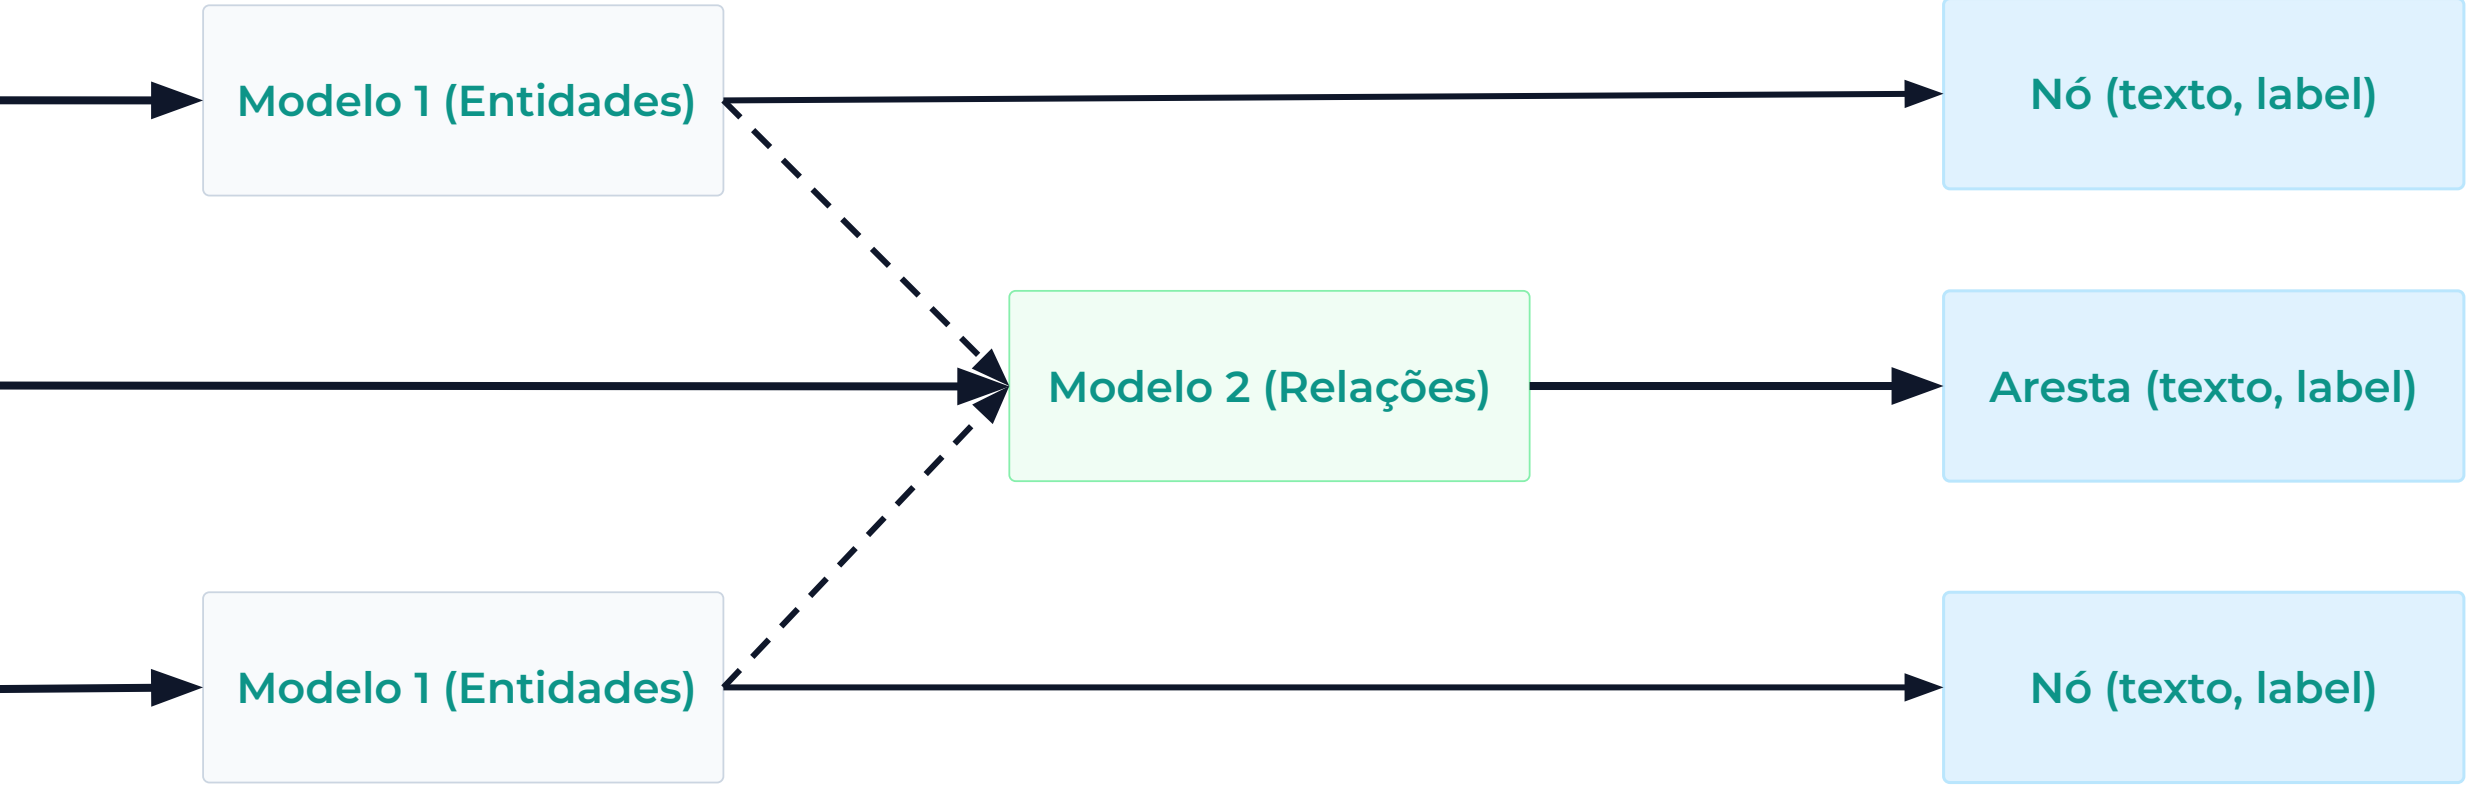
Fase 3: Integrando os Modelos 1 e 2



Fase 3: Integrando os Modelos 1 e 2



Fase 3: Integrando os Modelos 1 e 2



Gold Standard e Comparação de Modelos

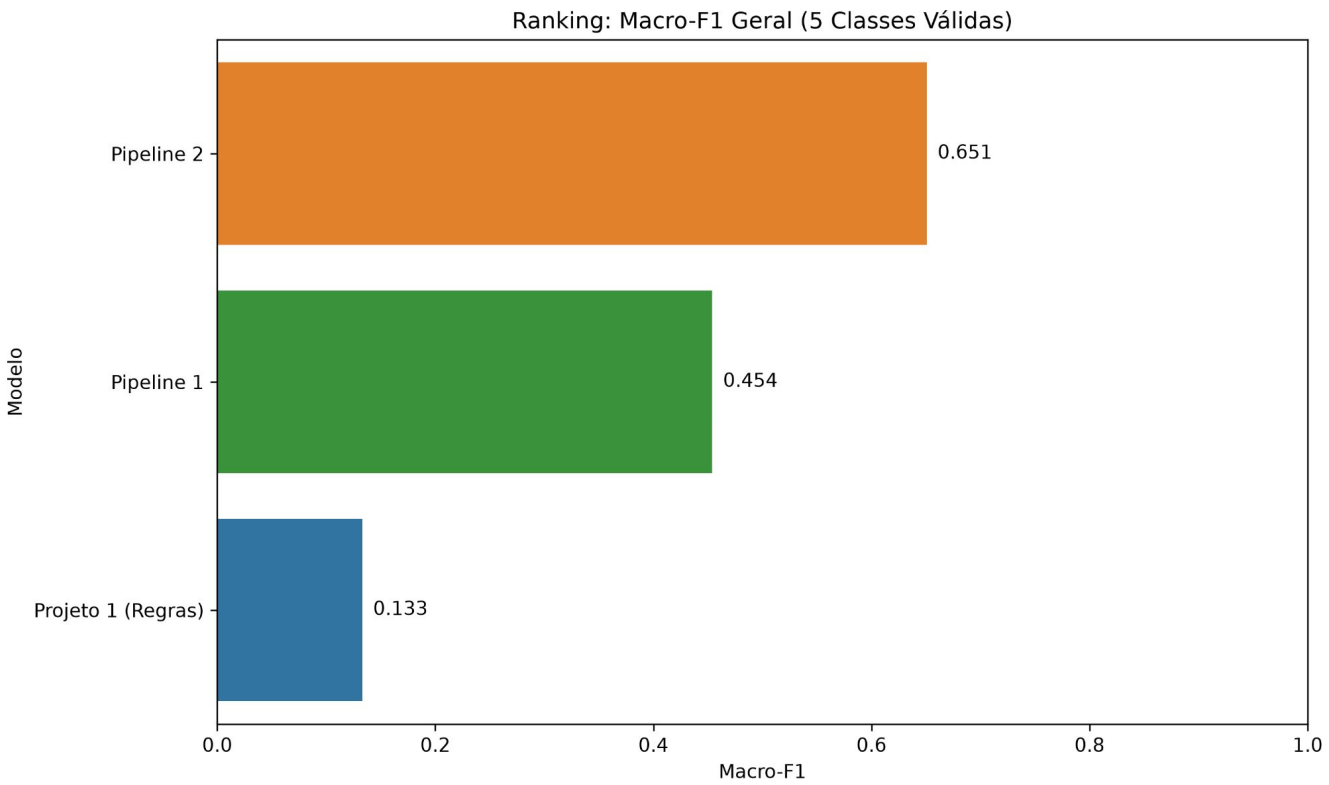
Validação via Gold Standard

- Base de teste pequena (125 instâncias), anotada com apoio de LLM
- Usada apenas na avaliação, sem vazamento de dados
- Avalia as 5 relações válidas (NO_RELATION e NOT_ENTITY ficam fora)

Métricas e Comparação com Baseline

- Métricas: Precision, Recall e Macro-F1
- Baseline: Projeto 1 (regras sintáticas)
- Comparados com o Pipeline 1 (Rede Neural/MLP) e o Pipeline 2 (Regressão Logística)

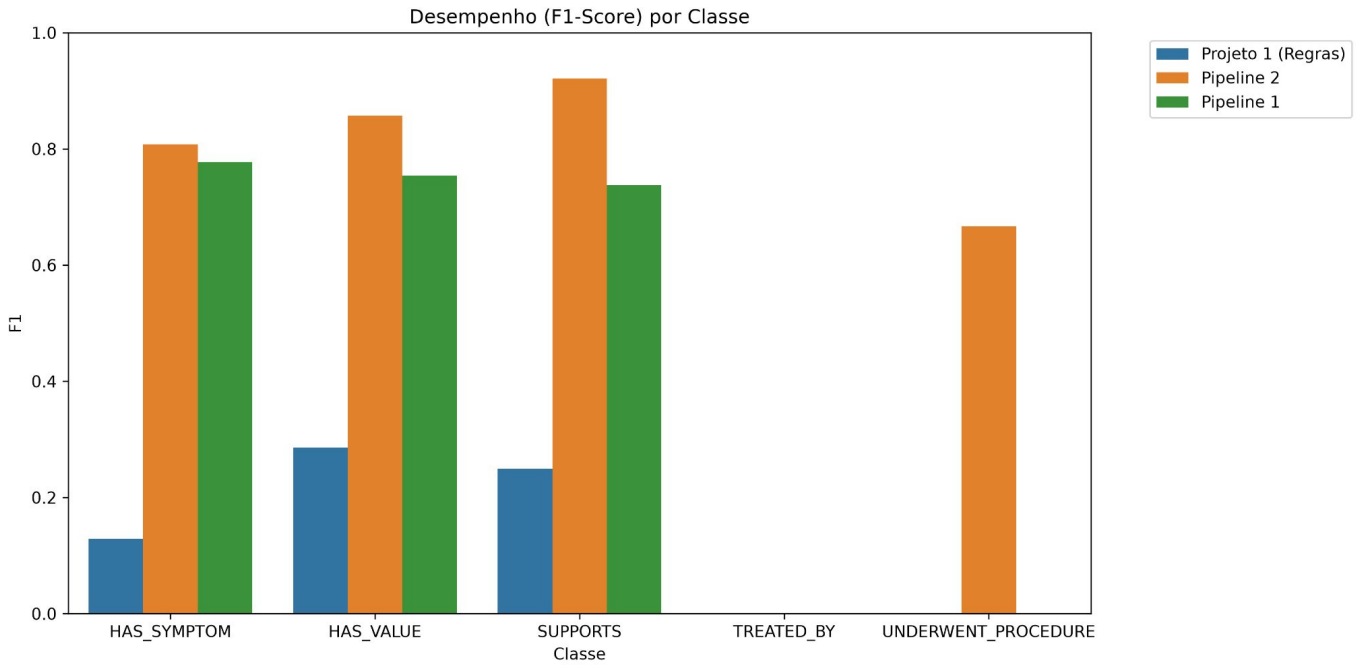
Resultados: Comparação de Modelos



Principais resultados

- **Projeto 1 (regras):** Macro-F1 0,13, com precisão de 0,60 mas recall de apenas 0,08. É preciso, mas cobre muito pouco.
- **Pipeline 1 (MLP, weak supervision):** Macro-F1 0,45
- **Pipeline 2 (Regressão Logística, anotação do Gold):** Macro-F1 0,65, o melhor resultado

Resultados: Desempenho por Classe



O que observamos

- **HAS_SYMPTOM, HAS_VALUE e SUPPORTS:** bom desempenho nos modelos de ML (F1 entre 0,75 e 0,92 no Pipeline 2)
- **UNDERWENT_PROCEDURE:** só o Pipeline 2 acerta (F1 ≈ 0,67)
- **TREATED_BY:** nenhum modelo acerta (classe rara, poucos exemplos)

Conclusões da Comparação

Qualidade > Quantidade

Poucos dados bem anotados superaram o volume com ruído da weak supervision (**0,65** vs **0,45**).

Regras: precisas, mas limitadas

Alta precisão, porém com recall muito baixo (**0,08**).

Limitações

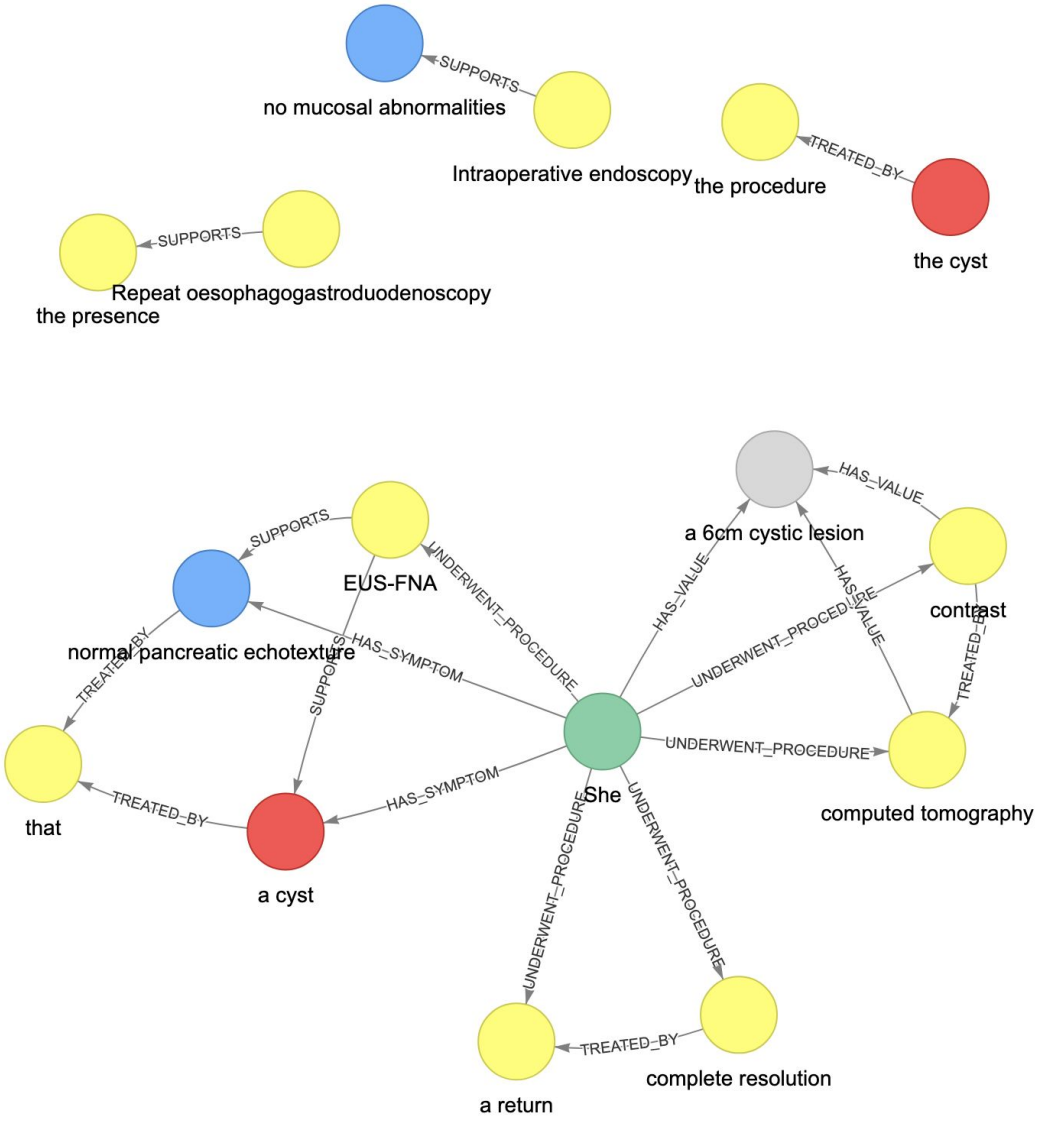
- **Gold pequeno** (125 instâncias) e anotado por LLM: resultados indicativos
- **Classes raras** (TREATED_BY, UNDERWENT_PROCEDURE): com poucos exemplos

Grafo Produzido com a Pipeline 2

Apresentação Interativa PyVis

O pipeline resulta na geração de um CSV contendo e1_text_normalized, e1_label, e2_text_normalized, e2_label, intermediate_text e relation_label estruturando o ambiente para plotagem interativa via biblioteca **PyVis**

- **Clusters:** Identificação de agrupamentos de sintomas
- **Inferência:** Cruzamento de dados estruturados para sugerir comorbidades não explícitas
- **Normalização:** Rede padronizada e limpa





Perguntas?

Obrigado pela atenção.

github.com/jpfrare/MC896-NLP







Fontes de Imagens



https://www.contentpowered.com/blog/tfidf-algorithm-content-seo/

Source: contentpowered.com



https://pt.dreamstime.com/furiosa-chefe-mulher-gritando-com-um-trabalhador-masculino-repreendendo-por-trabalho-incompetente

Source: dreamsite.com



https://tenor.com/view/dancing-spinosaurus-gif-3344822485292694929

Source: flaticon.com



Source: Gemini